

## Apêndice 1- Cálculo dos estimadores de máxima verossimilhança

Para uma sequência de V.A.s  $X = [X_1, X_2, X_3]$  que representam amostras iid de uma distribuição  $f(x|\theta)$ , temos que a função de verossimilhança pode ser escrita como

$$L(\theta) = \prod_{i=1}^n f(x_i|\theta)$$

O estimador MLE é encontrado ao maximizar  $L(\theta)$ :

$$\hat{\theta}_{MLE} = \underset{\theta}{\operatorname{argmax}} L(\theta)$$

1- Normal com  $\mu$  e  $\sigma$  desconhecidos

Temos a pdf da normal como

$$f(x|\mu, \sigma) = \frac{1}{\sqrt{2\pi} \sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Assim,  $L(\theta)$  é

$$L(\theta) = \prod_{i=1}^n \left( \frac{1}{\sqrt{2\pi} \sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} \right) = \left( \frac{1}{\sqrt{2\pi} \sigma} \right)^n e^{-\frac{\sum_{i=1}^n (x_i-\mu)^2}{2\sigma^2}}$$

Usamos o logaritmo de  $L(\theta)$  para calcular o valor máximo e obtemos

$$l(\theta) = \ln(L(\theta)) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{\sum_{i=1}^n (x_i-\mu)^2}{2\sigma^2}$$

Podemos agora calcular as derivadas parciais

$$x_i^2 - 2x_i\mu + \mu^2$$

$$\frac{\partial l}{\partial \hat{\mu}} = - \sum_{i=1}^n \frac{(2\hat{\mu} - 2x_i)}{2\hat{\sigma}^2} = 0$$

$$\therefore \sum_{i=1}^n 2\hat{\mu} = \sum_{i=1}^n 2x_i \quad \therefore n\hat{\mu} = \sum_{i=1}^n x_i \quad \therefore \hat{\mu} = \frac{\sum x_i}{n}$$

Para  $\sigma$ , temos:

$$l(\theta) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{\sum_{i=1}^n (x_i - \mu)^2}{2\sigma^2}$$

$$\frac{\partial l}{\partial \sigma} = -\frac{n}{2} \frac{4\sigma}{2\sigma^2} - \frac{\sum (-2)}{2\sigma^3} = 0$$

Assim, temos:

$$\frac{n}{\sigma} = \frac{\sum}{\sigma^3} \quad \therefore \sigma^2 = \frac{\sum}{n} = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$

Onde trocamos  $\mu$  por  $\hat{\mu}_{MLE}$

2 - Distribuição gamma

Temos a pdf da distribuição gamma como:

$$f(x|\alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}$$

Calculamos a verossimilhança como:

$$L(\theta) = \prod_{i=1}^n \frac{\lambda^\alpha}{\Gamma(\alpha)} x_i^{\alpha-1} e^{-\lambda x_i} = \left( \frac{\lambda^\alpha}{\Gamma(\alpha)} \right)^n e^{-\lambda \sum_{i=1}^n x_i} \prod_{i=1}^n x_i^{\alpha-1}$$

O logaritmo da verossimilhança:

$$l(\theta) = n\alpha \ln(\lambda) - n \ln(\Gamma(\alpha)) - \lambda \sum_{i=1}^n x_i + (\alpha-1) \sum_{i=1}^n \ln(x_i)$$

Calculamos as derivadas e igualamos a zero para obter os parâmetros:

$$\frac{\partial l}{\partial \lambda} = \frac{n\alpha}{\lambda} - S = 0$$

$$\frac{n\alpha}{\lambda} = S \therefore \hat{\lambda}_{MLE} = \frac{\alpha}{\bar{X}}$$

Agora para  $\alpha$

$$\frac{\partial l}{\partial \alpha} = n \ln(\hat{\lambda}) - \frac{n}{\Gamma(\alpha)} \Gamma'(\alpha) + \sum_{i=1}^n \ln(x_i) = 0$$

Vamos chamar  $\frac{\Gamma'(\alpha)}{\Gamma(\alpha)}$  de  $\phi(\alpha)$ , que é conhecida como a função digamma.

Assim, substituindo  $\lambda$  por  $\frac{\alpha}{\bar{X}}$ , temos:

$$n \ln\left(\frac{\alpha}{\bar{X}}\right) - n \phi(\alpha) + \sum_{i=1}^n \ln(x_i) = 0$$

$$n \ln(2) - n \ln(\bar{X}) - n \phi(\alpha) + \sum_{i=1}^n \ln(x_i) = 0$$

fatorando  $n$ , temos

$$\ln(2) - \ln(\bar{X}) - \phi(\alpha) + \overline{\ln(x_i)} = 0$$

Observação: Temos que não existe forma analítica para encontrar os valores dos parâmetros da distribuição gamma. Sendo assim, o código encontrará os valores dos parâmetros via MLE através de otimização numérica.